Detección de daños estructurales en nubes de puntos de dron

Comparación de PointNet++ y Point Transformer V3 preentrenado sobre el benchmark 3DAeroRelief (huracán Ian, 2022)

Jhonatan Velasco · 98251
Electiva de Ingeniería de Software · Universidad de San Buenaventura Cali



El problema: inspeccionar el daño tras un desastre

Hoy se hace a ojo, casa por casa

1

Lento

Un equipo revisa cada estructura en sitio; en un huracán son miles de edificaciones.

2

Subjetivo

El diagnóstico depende de la experiencia del inspector.

3

Riesgoso

El personal entra a zonas inestables o de difícil acceso.

La propuesta: volar un dron, reconstruir la zona como una nube de puntos 3D y que un modelo de aprendizaje profundo marque cada punto como edificación dañada, edificación sin daño, vía, árbol o fondo.

Los datos: 3DAeroRelief

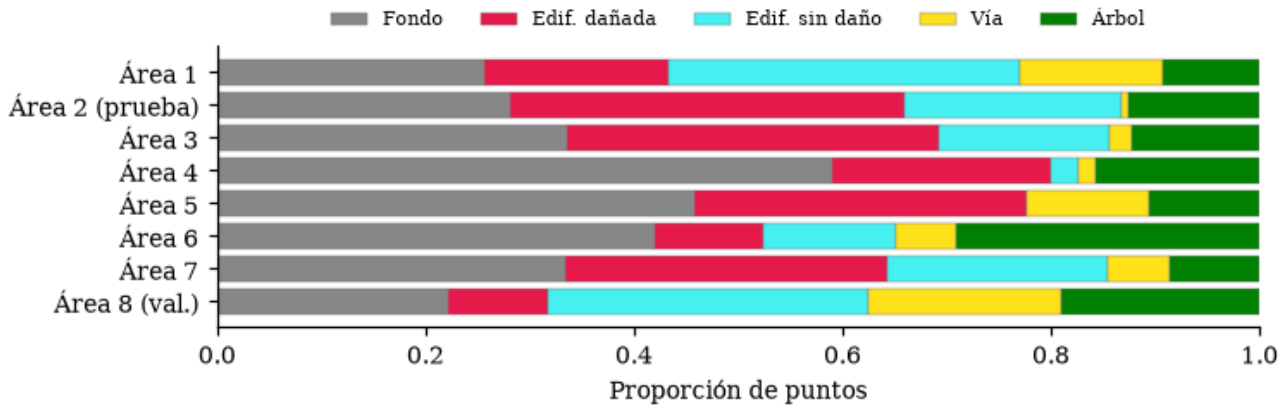
Primer benchmark 3D público de daño post-desastre (Scientific Data, 2026)

64 nubes de puntos

8 zonas de Florida

188 M puntos con etiqueta

5 clases



División oficial del benchmark

Entrenamiento: áreas 1, 3–7 · Validación: área 8 · Prueba: área 2 (8 nubes, 31 M puntos) — zonas que el modelo nunca vio.

Captura: video de dron → reconstrucción 3D con COLMAP.

Dos problemas del dataset que había que corregir

Ninguno estaba documentado; sin corregirlos, la altura no significa nada

↻ Nubes giradas

Problema

COLMAP entrega cada nube con orientación arbitraria: en varias, el “arriba” era el eje y.

Solución

Se alinea el suelo con PCA y el sentido se fija con las normales (apuntan al dron). 62 de 64 nubes verificadas.

↘ Escala distinta

Problema

En las áreas 4 y 6 las casas medían ~3,5 veces más que en el resto.

Solución

Se reescalan con la altura típica de las edificaciones (solo áreas de entrenamiento: factores 0,285 y 0,354).

Metodología: el mismo protocolo para todos los modelos

Así la comparación es justa

1 Fusionar etiquetas

2 Alinear y escalar

3 Vóxel 0,1 m + normales

4 Bloques 12 × 12 m

5 Entrenar y validar (área 8)

6 Probar en el área 2

Pérdida	Entropía cruzada ponderada por frecuencia de clase (las vías son solo el 6 %)
Selección	Se guarda el modelo con mejor mIoU en validación; la prueba se mira una sola vez
Métricas	mIoU (principal), IoU por clase, exactitud global y F1, a la resolución original (31 M puntos)
Repeticiones	Hasta 3 semillas por modelo (prioridad a los preentrenados) → media ± desviación

Cuatro modelos comparados

De una red clásica a transformers que ya “saben” de 3D

2017 · Desde cero

PointNet++

Red clásica: agrupa vecinos por radio y resume cada grupo.

1,0 M parámetros

2024 · Desde cero

PTv3

Transformer: ordena la nube con curvas que recorren el espacio y aplica atención.

46,2 M parámetros

2025 · Preentrenado

PTv3 + Sonata

Mismo transformer, preentrenado sin etiquetas en miles de escenas 3D (interiores).

38,9 M parámetros

2026 · Preentrenado

PTv3 + Utonia

Preentrenado sin etiquetas en nubes de muchos dominios, incluidas aéreas.

9,5 M parámetros

El preentrenamiento marca la diferencia

Área 2 (zona nunca vista), resolución original · PTv3 + Utonia: media de 3 semillas

75 %

IoU de edificación dañada

PointNet++: 59 %

0,545

mIoU (5 clases)

PointNet++: 0,436 · PTv3 desde cero: 0,447

84 %

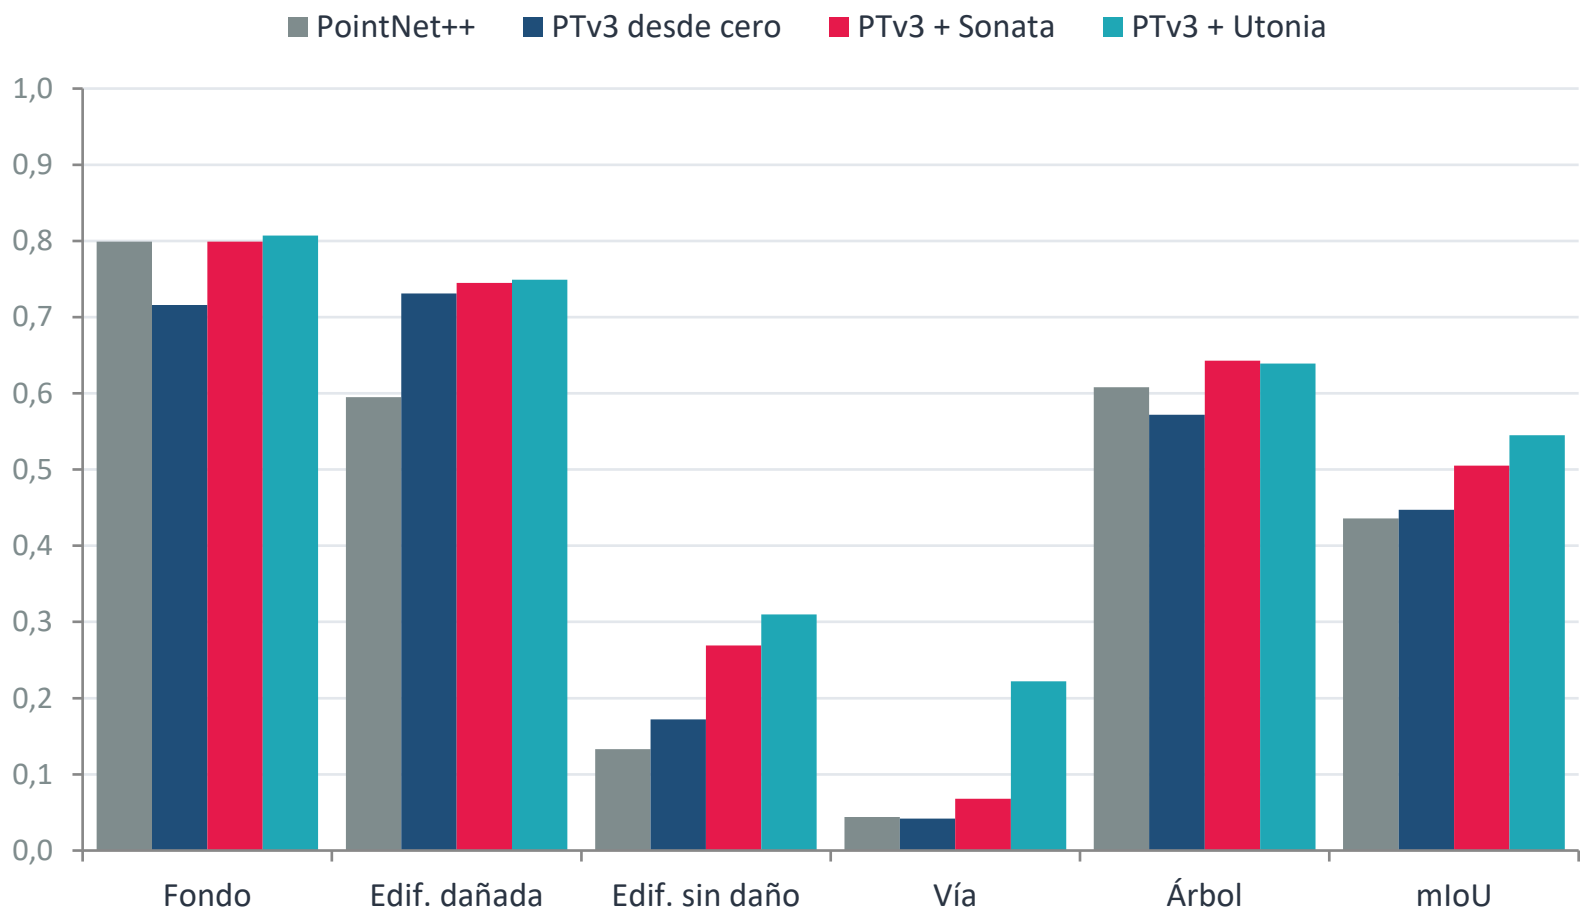
de puntos bien clasificados

PointNet++: 75 %

Contra el benchmark publicado: el mejor modelo del artículo (PTv3) obtiene mIoU 0,458 e IoU de daño 0,761. PTv3 + Utonia llega a 0,545 y 0,749. Es una comparación indicativa: aquí además se corrigieron la orientación y la escala de las nubes.

Resultados por clase

IoU en el área de prueba (resolución original, media de las semillas)

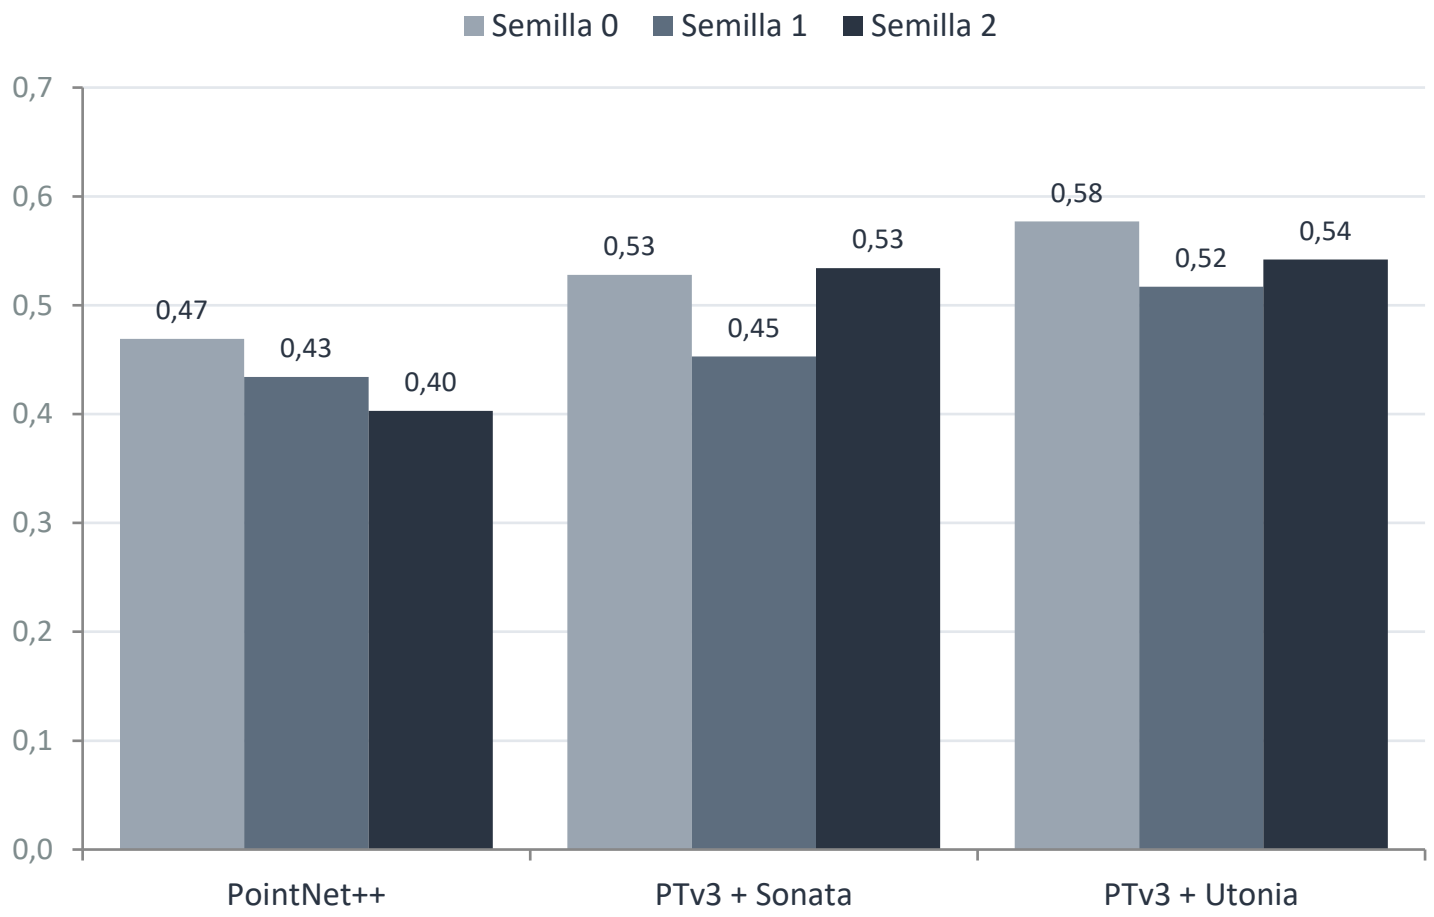


Lo que muestra

- Los modelos preentrenados mejoran sobre todo edificación sin daño y árboles.
- Vía casi no existe en el área de prueba (0,6 % de los puntos): su IoU es poco confiable.
- Edificación sin daño sigue siendo la clase más difícil.

¿Qué tan estable es el resultado?

mIoU de prueba de cada repetición (semillas 0, 1 y 2)

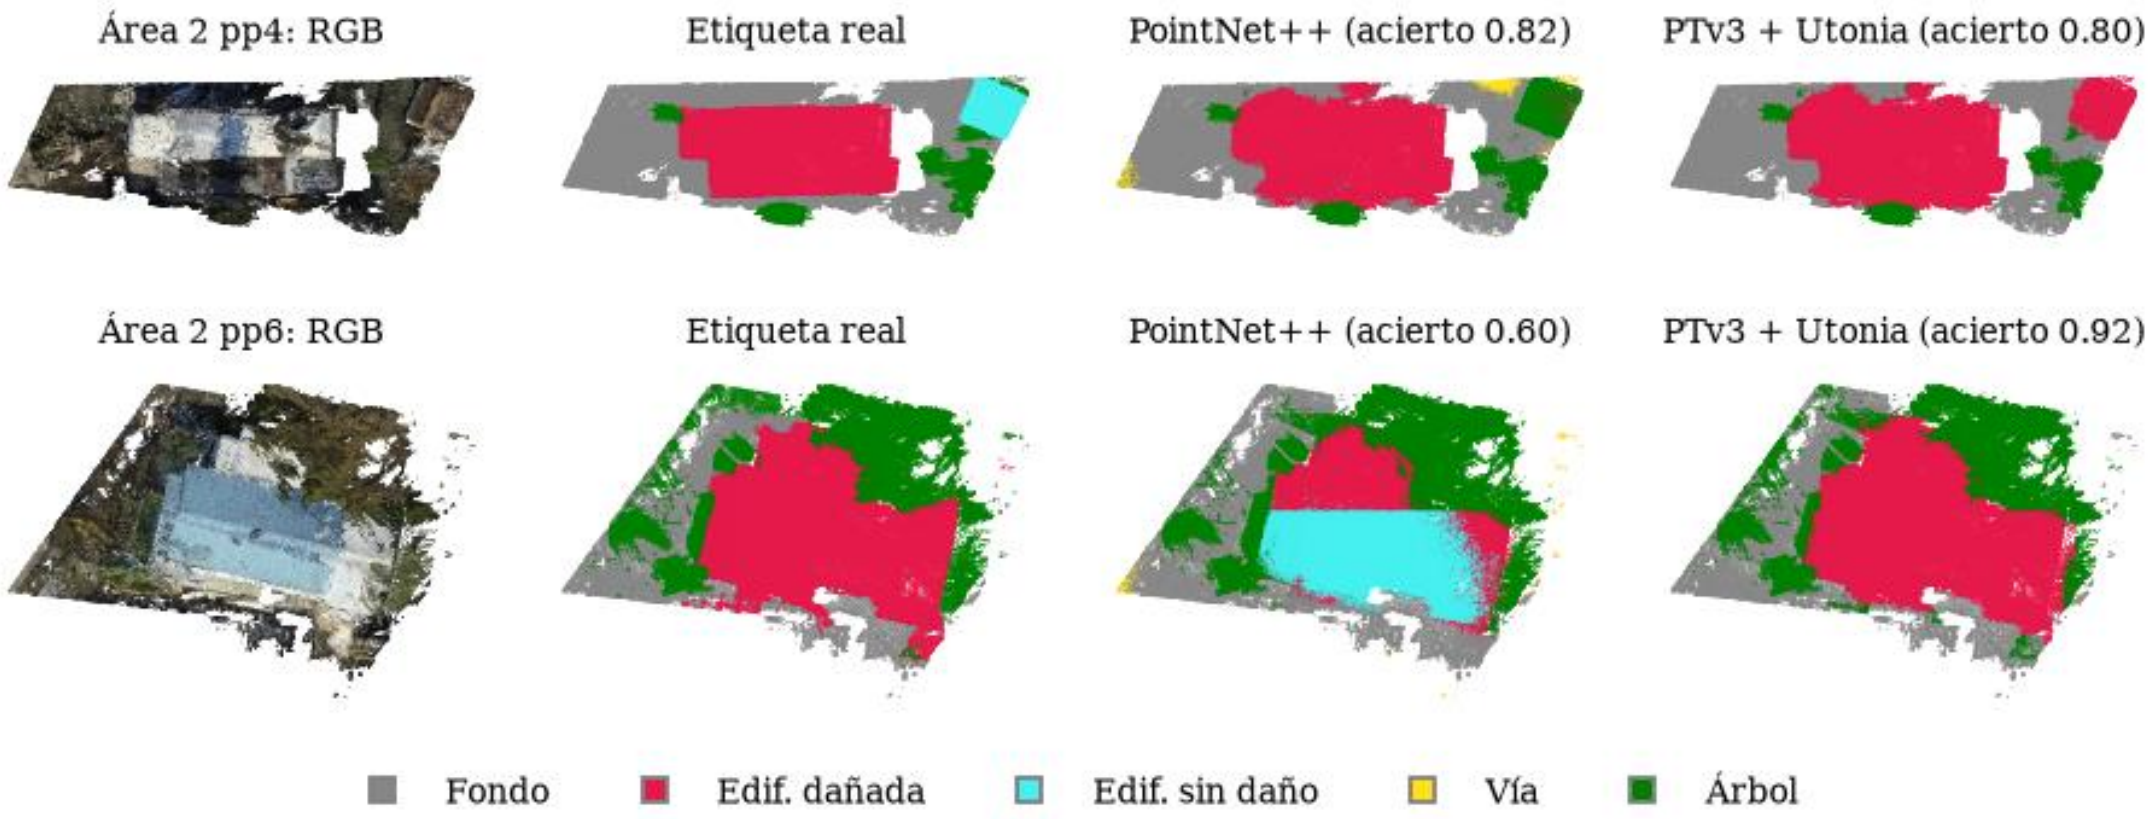


Lección

- Con la misma configuración, cambiar solo la semilla mueve el mIoU varios puntos.
- PointNet++: 0,40 a 0,47 · PTv3 + Sonata: 0,45 a 0,53 · PTv3 + Utonia: 0,52 a 0,58
- Por eso se reportan media ± desviación, y las diferencias pequeñas entre modelos no son concluyentes.

Lo que ve cada modelo

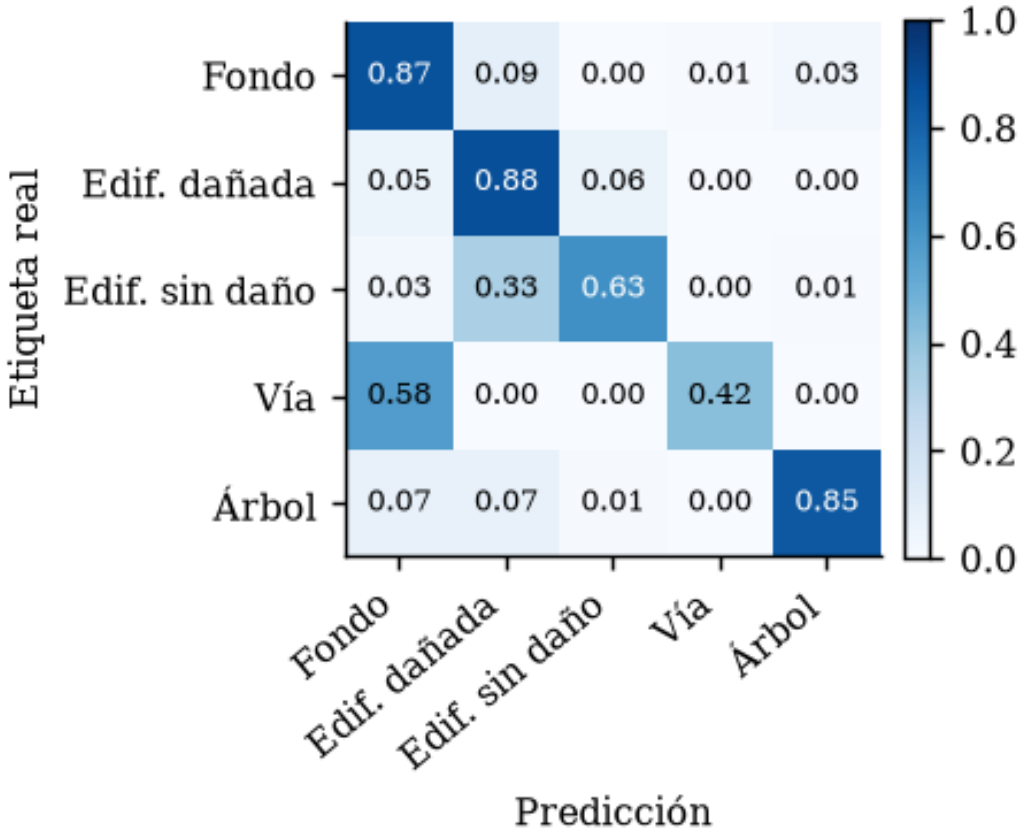
Vista superior de dos nubes de prueba



Abajo: PointNet++ marca como "sin daño" (celeste) buena parte del techo dañado; PTv3 + Utonia lo reconoce casi completo.

¿Dónde se equivoca?

Matriz de confusión de PTv3 + Utonia (área de prueba)



1

Detecta bien el daño

El 88 % de los puntos de edificación dañada se reconoce correctamente.

2

Confunde casas sanas

El 33 % de los puntos de edificación sin daño se marca como dañada: un techo intacto y uno con daño leve se parecen mucho.

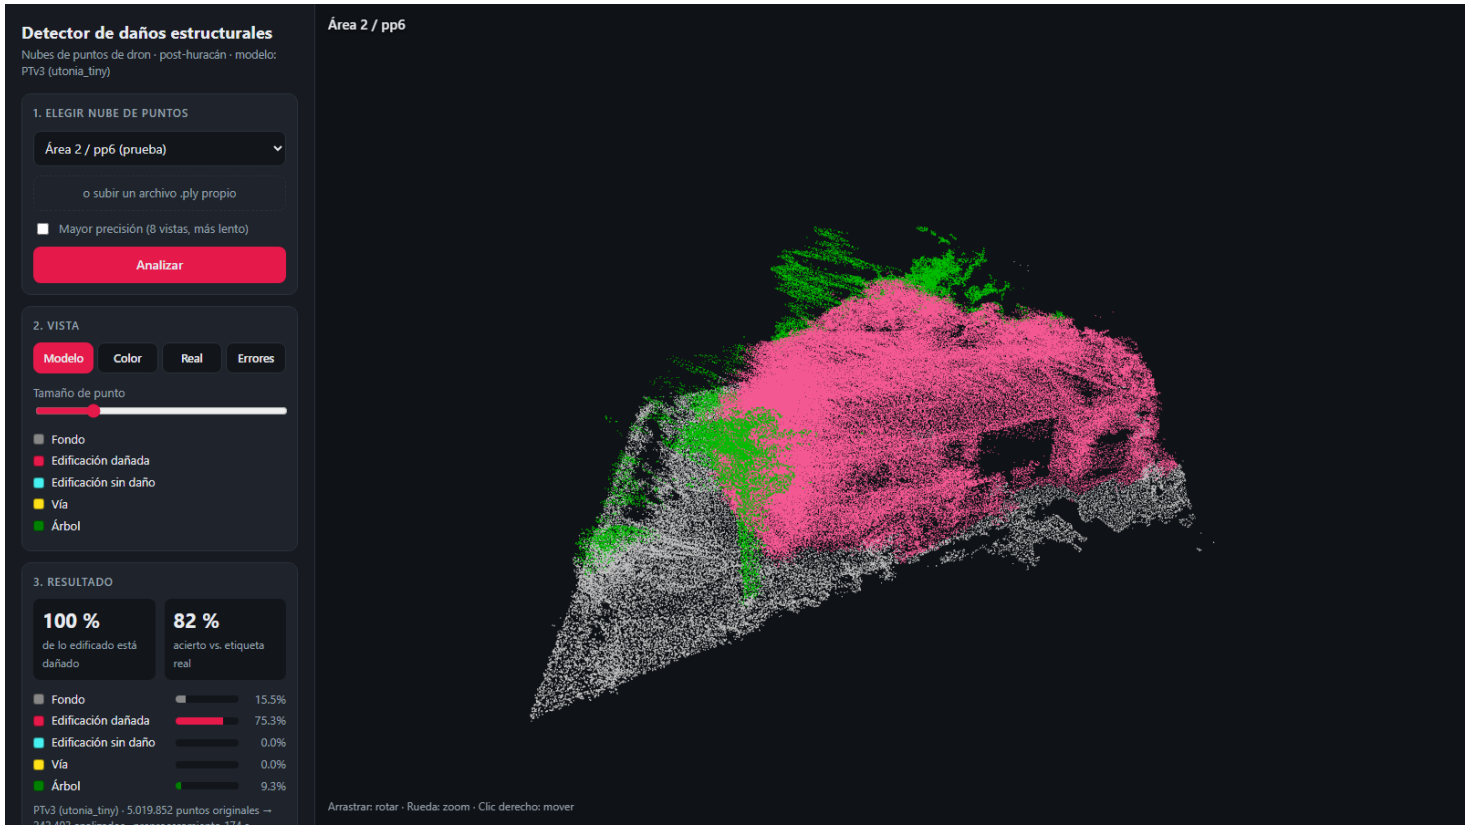
3

Vía ↔ fondo

El 58 % de la vía se confunde con fondo: ambas son superficies planas a ras de suelo y la vía es muy escasa.

La herramienta: del modelo a una aplicación

Aplicación web local, funciona sin internet



1 **Elegir o subir**

una nube .ply

2 **Analizar**

mismo preprocesamiento del experimento

3 **Ver en 3D**

modelo · color · real · errores

4 **Resumen**

% de lo edificado dañado

Python (servidor) + three.js (visor 3D) · reutiliza el mismo código del experimento

Conclusiones

Funciona

En una zona que nunca vio, PTv3 + Utonia identifica la edificación dañada con IoU 0,75.

El preentrenamiento importa más que la arquitectura

Entrenado desde cero, PTv3 rinde como PointNet++ (0,45 vs 0,44); preentrenado, lo supera (0,50 y 0,55).

Revisar los datos y repetir

Corregir orientación y escala fue necesario, y repetir con varias semillas evitó conclusiones apresuradas.

Siguiente paso

Estabilizar el ajuste de los modelos preentrenados y distinguir mejor las casas sanas.

¡Gracias! · Preguntas